데이터 전처리

🔖 RAG 전처리

📌 경기 규정 문서

원본 데이터

파일	설명
`section_a_general_provisions.pdf`	FIA 2026 F1 일반 규정
`section_b_sporting.pdf`	FIA 2026 F1 스포팅 규정
`section_c_technical.pdf`	FIA 2026 F1 기술 규정
`section_d_financial.pdf`	FIA 2026 F1 재정 규정
`section_f_operational.pdf`	FIA 2026 F1 운영 규정

---

1. PDF → Markdown 변환

> PDF의 계층적 조항 구조를 보존하기 위해 Markdown으로 변환

FIA 규정 PDF는 LLM이 직접 읽기 어려운 바이너리 포맷이다. 또한 `SECTION → ARTICLE → 조항(B1.1.1)` 형태의 깊은 계층 구조를 가지고 있어, 단순 텍스트 추출만으로는 구조 정보가 사라진다. Markdown은 헤더(`##`)와 리스트(`-`)로 이 계층을 표현할 수 있고, RAG 청킹 시 헤더 기준으로 의미 단위 분할이 가능하기 때문에 Markdown을 중간 포맷으로 선택했다.

색상별 처리 방식

색상	의미	처리 결과
검정	이전 Issue와 동일한 본문	✅ 그대로 유지
분홍	새로 추가/변경된 텍스트	✅ 내용 유지, 색상 구분 소실
~~분홍 취소선~~	삭제된 텍스트	❌ 완전 삭제
[빨강]	Advisory Committee / Governance 정보	❌ 완전 삭제
[주황]	관련 FIA F1 Document 참조	❌ 완전 삭제

색상	의미	처리 결과
[초록]	비구속적 코멘트/설명	❌ 완전 삭제

알려진 파싱 한계

- 특수문자 깨짐: `official` → `o`icial`
- 2열 레이아웃 병합 오류: 나란히 배치된 리스트가 한 줄로 합쳐짐
- 일부 문장 앞부분 누락: 컬럼 경계 오감지로 문장이 중간부터 시작
- 들여쓰기 레벨 붕괴: 하위 항목이 최상위 레벨로 올라오는 경우 발생

2. 청킹 (Chunking)

- 아티클 단위(`B1.1`, `C2.3` 등) 헤더 기준으로 분할
- 정규식 패턴: `r'^#{1,3}\\s+\\*\\*[A-Z]\\d+\\.\\d+'`

규정 문서는 조항 단위로 독립적인 의미를 가지기 때문에, 고정 길이 분할 대신 아티클 헤더(`B1.1`, `C2.3` 등) 기준의 의미 단위 분할을 적용, 검색 시 관련 조항 전체가 context로 제공되어 답변 품질이 높아지도록 청킹했다.

🌐 Wikipedia 데이터

원본 데이터

파일	Wikipedia 페이지	섹션 수
`f1_intro_wiki.json`	Formula One	36개
`f1_history_wiki.json`	History of Formula One	23개
`f1_flags_wiki.json`	Racing flags	25개

1. 크롤링

Wikipedia의 F1 관련 3개 페이지를 섹션 단위로 크롤링하여 페이지별로 JSON 파일로 저장했다.
각 항목은 아래 구조로 구성된다.

2. 청킹 (Chunking)

Wikipedia 문서는 이미 섹션 단위로 나뉘어 있으므로, 크롤링 시 섹션 제목(`title`)을 기준으로 분할하여 저장했다. 섹션별로 독립적인 주제를 다루고 있어 추가 분할 없이 그대로 사

용했다.

3. 품질 필터링

필터 유형	설명
빈 항목	빈 title 또는 빈 content 제거
중복	동일 섹션 중복 제거
지나치게 짧은 본문	의미 있는 정보를 담기 어려운 단문 섹션 제거

🏁 F1 서킷 데이터

원본 데이터

항목	내용
출처	Jolpica API
파일	`f1_circuits.json`
총 서킷 수	78개

1. API 크롤링

Jolpi.ca API에서 F1 역대 서킷 정보를 수집하여 JSON으로 저장했다.

2. 청킹 (Chunking)

서킷 1개 = 청크 1개로 구성했다. 서킷 정보는 각각 독립적인 단위이며 분량이 짧아 추가 분할 없이 그대로 사용했다.

🏎️ 타이어 데이터

원본 데이터

항목	내용
출처	Pirelli 공식 웹사이트
URL	`https://www.pirelli.com/tires/enus/motorsport/f1/tires`
파일	`pirelli_f1_tires.txt`

1. 크롤링

- Pirelli 공식 웹사이트의 F1 타이어 소개 페이지를 크롤링하여 txt 파일로 저장했다.
- 페이지 내 광고, 네비게이션 등 불필요한 요소를 제거하고 본문 텍스트만 추출했다.

2. 청킹 (Chunking)

타이어 종류별로 독립적인 의미를 가지므로 섹션 제목 기준으로 분할했다.

섹션	설명
개요	18인치 타이어 개발 과정 및 전반적인 설명
SLICK TIRES	슬릭 타이어 전체 개요 및 사이즈 정보
C0 ~ C5	컴파운드별 특성 및 적합 서킷 조건
CINTURATO GREEN INTERMEDIATE	인터미디에이트 타이어 설명
FULL WET BLUE	풀웻 타이어 설명

📖 F1 용어 사전 데이터

원본 데이터

항목	내용
출처	Formula 1 공식 웹사이트
URL	`https://www.formula1.com/en/latest/article/f1-glossary-*`
파일	`f1_glossary_all.json`
총 용어 수	244개
카테고리	A-E / F-J / K-O / P-T / U-Z

---

1. 크롤링

Formula 1 공식 웹사이트의 용어 사전 페이지를 카테고리별로 크롤링, 하나의 JSON으로 병합했다.

2. 청킹 (Chunking)

용어 1개 = 청크 1개로 구성했다. 각 용어는 독립적인 의미 단위이며, `term` + `description` + `example` 조합으로 충분한 맥락을 제공하기 때문에 추가 분할 없이 그대로 사용했다.

🎯 파인튜닝 전처리

- PDF → Markdown → Chunking → QA 생성 → 품질 필터링 → JSONL

> RAG 전처리 단계에서 변환된 Markdown, JSON 파일을 입력으로 사용

1. PDF → Markdown 변환

RAG 전처리와 동일

2. 청킹 (Chunking)

RAG 전처리와 동일

3. QA 생성

- 모델: `gpt-4.1-mini`
- 언어: 한국어
- 각 청크를 context로 제공 후 질문-답변 쌍 생성

4. 품질 필터링

필터 유형	설명
사실 오류	규정 내용과 불일치하는 답변 제거
불확실 표현	`~일 수 있습니다`, `~인지 불분명` 등 제거
리다이렉트 패턴	`다른 조항을 참조하세요` 등 제거
Filler 패턴	형식적 도입/마무리 문장 제거
빈 항목	빈 질문 또는 빈 답변 제거
중복	동일 질문-답변 쌍 제거